# CCF 2025 HIP 编程竞赛项目报告

付嘉晨, 黄俊雄

2025年9月11日

### 1 项目概述

本项目实现了 CCF 2025 HIP 编程竞赛的三个 GPU 加速算法挑战: **前缀和、Softmax** 和**全对最短路径 (APSP)**。所有算法均基于 HIP/ROCm 实现,针对 AMD GPU 架构优化,采用单 GPU 执行策略。项目在算法实现、性能优化、输出加速等方面取得了显著成果。

## 2 算法实现

#### 2.1 前缀和 (Prefix Sum)

**算法特点.** 1) 实现分块扫描三阶段算法: 块内扫描  $\rightarrow$  块和扫描  $\rightarrow$  偏移累加; 2) 支持 Hillis-Steele 和 Blelloch 两种扫描实现,可编译时切换; 3) 使用共享内存优化块内计算,支持非 2 次幂长度数组。

**关键优化**. 1) BLOCK\_SIZE=256, 适配 AMD GPU 架构; 2) 递归扫描处理大规模数据, 层数为  $O(\log_B N)$ ; 3) 高性能输出:32MB 缓冲区 +std::to\_chars, 显著减少 I/O 开销。

#### 2.2 Softmax

**算法特点**. **1)** 实现数值稳定的 softmax:  $y_i = \frac{\exp(x_i - \max)}{\sum (\exp(x_j - \max))}$ ;**2)** 两阶段归约: 先求全局最大值,再计算指数和并归一化;**3)** 严格遵循数值稳定性要求,避免溢出/下溢。

关键优化. 1) 4 个专用 GPU 内核: 分块最大值、全局最大值归约、指数和计算、归一化; 2) 分母保护: S + 1e-12 确保满足容差要求; 3) FAST\_OUTPUT 优化: 输出性能提升 3-6 倍, 特别适用于大规模数据。

#### 2.3 全对最短路径 (APSP)

**算法特点.** 1) 基于分块 Floyd-Warshall 算法, 三阶段执行: (a) Phase 1: 处理 pivot 块 (k,k), (b) Phase 2: 更新第 k 行/列块, (c) Phase 3: 更新其余所有块; 2) 使用共享内存进行块内 tile 复用,减少全局内存访问。

**关键优化.** 1) 内存优化: 页锁定内存 + 异步传输, H2D 传输提升 35 倍 (355ms→9ms); 2) GPU 计算优化: HIP 事件精确同步替代设备同步, 性能提升 19-26%; 3) 编译优化: 现代编译标志 (--offload-arch)、循环展开、分支预测; 4) 输出优化: 32MB 缓冲区, 输出速度从 100MB/s 提升至 540MB/s。

# 3 技术亮点

#### 3.1 渐进式性能优化策略

以 APSP 为例,采用系统性的优化方法: **1) 阶段 1**:页锁定内存优化,D2H 性能提升 82%; **2) 阶段 2**: 异步传输 + 流并行,H2D 性能提升 97%; **3) 阶段 3**: GPU 计算核心优化,整体性能提升 19-26%。

#### 3.2 统一的高效输出框架

三个项目均实现 FAST\_OUTPUT 优化: 1) 大缓冲区 (32MB) 减少系统调用; 2) std::to\_chars 替代格式化输出; 3) 关闭 iostream/stdio 同步,启用全缓冲模式; 4) 保持字节级输出兼容性。

#### 3.3 工程化实践

**1) 错误处理**: 完整的 HIP API 错误检查和资源管理; **2) 可配置性**: 编译时开关控制优化策略 (FAST\_OUTPUT、算法选择); **3) 测试验证**: 完整的测试套件,自动化校验正确性; **4) 性能监控**: 详细的分阶段计时,支持性能分析。

### 4 性能结果

#### 4.1 定量性能数据 (基于 MI100/gfx908)

 项目
 关键优化
 性能提升
 代表性指标

 Prefix Sum
 Blelloch 扫描 + 快速输出
 显著减少 I/O 开销
 支持 1 亿级元素

 Softmax
 数值稳定 + 快速输出
 输出加速 3-6 倍
 满足 1e-6 绝对容差

 APSP
 综合优化
 传输加速 35 倍

表 1: 基于 MI100/gfx908 的性能数据

### 4.2 关键性能突破

1) 数据传输: 从 388ms 降至 15ms (APSP); 2) 输出效率: 从 100MB/s 提升至 540MB/s; 3) GPU 利用率: 事件驱动同步显著提升并行度。

## 5 技术创新

1) 混合同步策略: HIP 事件 + 流实现精确依赖管理,避免过度同步; 2) 自适应内存管理:页锁定内存 + 异步传输的最佳实践组合; 3) 编译器协同优化:现代 HIP 编译标志 + 手工循环优化相结合; 4) 跨项目复用模式:高效输出框架在三个算法间的成功移植。